

Documentación Técnica: Pipeline de Datos de Fútbol

Implementación de Data Lake House en AWS para Analítica Avanzada

Proyecto desarrollado para
Federación Mexicana de Futbol (FMF)

Implementado por
Equipo 6- Ingeniería de Datos, UNAM 2026.

26 de mayo de 2026

1. Configuración del Entorno

Se describen los componentes de infraestructura, scripts de automatización y el diseño lógico del modelo de datos implementado en AWS para el procesamiento y análisis del histórico de partidos de selecciones nacionales de fútbol. La solución procesa datos en curso desde una API externa y los consolida en un almacén columnar optimizado en Amazon S3, gobernado por AWS Glue y consultado mediante Amazon Athena.

2. Inventario de Recursos de Infraestructura

Servicio AWS	Nombre/Identificador	Función Principal
Amazon EC2	unam-2026-ingenieriadedatos-grupo6	Instancia con las instalaciones necesarias para ejecutar todos los scripts de python necesarios para el proyecto
Amazon S3	unam-2026-ingenieriadatos-equipo6	Bucket centralizado del Data Lake que almacena las tres capas de madurez de datos (/1bronze/ , /2silver/ , /3gold/)
AWS Glue Job	silver1 (Engine: Spark 3.3 , Python 3)	Job ETL Serveless que procesa el script de PySpark para la limpieza, tipado y particionamiento de datos.
AWS Glue Crawler	crawler-silver-parquet	Rastreador encargado de inspeccionar las carpetas particionadas en S3, inferir el esquema y registrar la metadata

Servicio AWS	Nombre/Identificador	Función Principal
Amazon Athena	Motor Serveless (Query Engine V3)	Entorno para ejecutar consultas analíticas distribuidas en lenguaje SQL estándar sobre el catálogo de datos.

3. Especificaciones de los Pipelines (ETL)

3.1. Ingesta (API-Football —-----S3 Capa Bronze)

La ingesta de datos del proyecto se realiza mediante scripts desarrollados en Python y ejecutados en una instancia Amazon EC2. Estos scripts se conectan a la API-Football utilizando solicitudes HTTP autenticadas con una API Key para obtener información histórica de partidos internacionales de distintas selecciones nacionales.

El proceso comienza consultando múltiples temporadas por cada equipo seleccionado, recuperando datos como fecha del partido, selección local, selección visitante, goles anotados y torneo correspondiente. Posteriormente, los datos obtenidos en formato JSON son transformados y filtrados para conservar únicamente los partidos disputados desde agosto de 2022.

Una vez procesados, los registros son almacenados en archivos CSV individuales por selección nacional. Después, mediante otro script automatizado, estos archivos son cargados hacia Amazon S3 dentro de la capa Bronze del Data Lake, organizados en carpetas por país.

3.2. Transformación (EMR/Glue —----- Silver)

El job de AWS Glue ejecuta un script distribuido en PySpark (silver1.py) que aplica de manera estricta las siguientes transformaciones y reglas de calidad de datos:

- *Codificación correcta:*

Forzado de lectura de fuentes en formato UTF-8 para prevenir la ruptura de caracteres con acentos en los nombres de las selecciones

- *Limpieza de cadenas:*

Aplicación de las funciones `.WithColumn()` combinadas con `upper()` y `trim()` para estandarizar los nombres de los equipos rivales y eliminar espacios residuales

- *Casteo de tipos:*

Conversión de columnas de texto a tipos de datos nativos adecuados para la analítica numerica:

- `Goles_local` — `IntegerType()`
- `Goles_visitante` — `IntegerType()`
- `Fecha` — `TimestampType()`

- *Filtrado de Rangos como regla de calidad:*

Eliminar las anomalías mediante cláusulas `filter()` permitiendo únicamente registros donde el conteo de goles se ubique en un rango lógico de entre 0 y 20 por partido.

- *Optimización del particionamiento:*

El `DataFrame` limpio se escribe en la Capa Silver utilizando el formato columnar optimizado Parquet, aplicando un particionamiento por columna de control year.

- Ruta de salida:

s3://unam-2026-ingenieriadatos-equipos6/2silver/[seleccion]/year=YYYY/

3.3. Refinamiento (S3 Capa Silver — Amazon Athena — Capa Gold)

Un AWS Glue Crawler mapea de forma dinámica la raíz de la capa Silver. Al identificar las subcarpetas generadas por PySpark, actualiza las particiones dentro del Data Catalog lo que expone la tabla particionada hacia Amazon Athena.

A través de Amazon Athena, se ejecutan queries analíticas para generar vistas agregadas con KPIs clave (Total de partidos, victorias, empates, derrotas, % de efectividad, goles a favor y en contra). Los resultados de alto valor de negocio se almacenan en la capa final en la ruta:

s3://unam-2026-ingenieriadatos-equipos6/3gold/

4. Diccionario de Datos (Capa Gold)

Se detalla un esquema de los tipos de datos resultante en el catálogo

glue-2silver.2silver:

Nombre	Tipo de Dato (Athena)	Regla de Negocio
<i>fecha</i>	timestamp	Fecha y hora en la que se disputó el partido
<i>torneo</i>	string	Nombre oficial de la competencia
<i>equipo_local</i>	string	Nombre del equipo que jugó en condición de local (En mayúsculas)
<i>equipo_visitante</i>	string	Nombre del equipo que jugó en condición de visitante (En mayúsculas)
<i>goles_local</i>	int	Cantidad de anotaciones marcadas por el local (0-20)
<i>goles_visitante</i>	int	Cantidad de anotaciones marcadas por el visitante (0-20)
<i>partition_0</i>	string	Llave de partición primaria que corresponde al país analizado
<i>year</i>	string	Llave de partición secundaria (Año del partido)

5. Guía de Ejecución y Monitoreo

Para iniciar el procesamiento ET distribuido sobre los datos de manera manual utilizando la interfaz de línea de comandos de AWS, se debe ejecutar la siguiente instrucción:

```
aws glue start-job-run --job-name silver1
```

El estado de las ejecuciones se audita de forma directa en la consola de AWS Glue Monitoring y los flujos de impresión se dirigen a logs específicos en Amazon CloudWatch.

Las pruebas de rendimiento ejecutadas sobre el cluster Serverless arrojan un tiempo promedio de procesamiento de 1 minuto y 54 segundos para la transformación masiva de la capa Bronze a Silver, siendo esta altamente eficiente y escalable frente al crecimiento de la información.