

Documentación Funcional: Pipeline de Datos de Fútbol

Implementación de Data Lake House en AWS para Analítica Avanzada

Proyecto desarrollado para
Federación Mexicana de Futbol (FMF)

Implementado por
Equipo 6- Ingeniería de Datos, UNAM 2026.

26 de mayo de 2026

1. Objetivo del Documento

Este documento describe las funcionalidades del sistema desde una perspectiva deportiva y estratégica para el usuario. En este texto se redacta lo qué puede hacer el sistema, quiénes lo utilizan y qué valor aporta al cuerpo técnico de la selección mexicana contemplando los futuros partidos en el mundial de 2026.

2. Roles de Usuario

Para asegurar el correcto flujo de información y seguridad, se definen los siguientes perfiles

Rol	Responsabilidades
Analista de Negocio	Consulta de las métricas con la cantidad de victorias, empates, derrotas, promedio de goles,etc.Con lo cual se realizarán análisis y generación de reportes sobre los equipos rivales en el mundial de 2026.
Data Engineer (Soporte)	Este equipo se concentrará en monitorear la extracción en la API-Football, además de asegurar que el procesamiento de AWS Glue se ejecute de forma correcta
Stakeholder / Directivo (Cuerpo Técnico)	Realizarán las revisiones de las estadísticas e historial de los rivales para la toma de decisiones y planeación de los partidos del mundial 2026 a través del dashboard

3. Procesos de Negocio Soportados

3.1. Centralización de partidos


El sistema consolida automáticamente los resultados de los partidos internacionales que fueron disputados en el periodo de agosto del 2022 a mayo del 2026 estos datos fueron extraídos directamente desde la API-Football, donde deposita los datos en estado crudo dentro de la capa bronce, en formato CSV. Esto permite que los datos mantengan el histórico y elimina la necesidad de buscar y registrar información manualmente.

1	fecha	local	visitante	goles_local	goles_visitant	torneo	
2	2022-11-22T1	Mexico	Poland	0	0	World Cup	
3	2022-11-26T1	Argentina	Mexico	2	0	World Cup	
4	2022-11-30T1	Saudi Arabia	Mexico	1	2	World Cup	
5	2023-03-24T0	Suriname	Mexico	0	2	CONCACAF Nations League	
6	2023-03-27T0	Mexico	Jamaica	2	2	CONCACAF Nations League	
7	2022-09-01T0	Mexico	Paraguay	0	1	Friendlies	
8	2022-09-25T0	Mexico	Peru	1	0	Friendlies	
9	2022-09-28T0	Mexico	Colombia	2	3	Friendlies	
10	2022-11-09T2	Mexico	Iraq	4	0	Friendlies	
11	2022-11-16T1	Mexico	Sweden	1	2	Friendlies	
12	2023-06-16T0	USA	Mexico	3	0	CONCACAF Nations League	
13	2023-06-18T2	Panama	Mexico	0	1	CONCACAF Nations League	
14	2023-04-20T0	USA	Mexico	1	1	Friendlies	
15	2023-06-26T0	Mexico	Honduras	4	0	CONCACAF Gold Cup	
16	2023-06-30T0	Haiti	Mexico	1	3	CONCACAF Gold Cup	
17	2023-07-03T0	Mexico	Qatar	0	1	CONCACAF Gold Cup	
18	2023-06-08T0	Mexico	Guatemala	2	0	Friendlies	
19	2023-06-11T0	Mexico	Cameroon	2	2	Friendlies	
20	2023-07-09T0	Mexico	Costa Rica	2	0	CONCACAF Gold Cup	
21	2023-07-13T0	Jamaica	Mexico	0	3	CONCACAF Gold Cup	
22	2023-07-16T2	Mexico	Panama	1	0	CONCACAF Gold Cup	
23	2023-09-10T0	Mexico	Australia	2	2	Friendlies	
24	2023-09-12T2	Mexico	Uzbekistan	3	3	Friendlies	
25	2023-10-15T0	Mexico	Ghana	2	0	Friendlies	
26	2023-10-18T0	Mexico	Germany	2	2	Friendlies	

3.2. Limpieza Automática de Datos

Una vez que se tienen los datos en crudo, se ejecuta un proceso automatizado que detecta y corrigen las inconsistencias de forma automática, además se aplican reglas de calidad como la eliminación de algunos valores nulos, la estandarización de los nombres de los equipos y la valoración de goles posibles en un rango de 0 a 20 .

Finalmente cada uno de sus resultados se almacenan en un formato Parquet donde se dividen por años, garantizando que el análisis posterior se base en una sola versión .



#	fecha	local	visitante	goles_local	goles_visitante	torneo	partition_0
1	2022-09-01 01:00:00.000	MEXICO	PARAGUAY	0	1	Friendlies	mexico
2	2022-09-25 01:00:00.000	MEXICO	PERU	1	0	Friendlies	mexico
3	2022-09-28 02:00:00.000	MEXICO	COLOMBIA	2	3	Friendlies	mexico
4	2022-11-09 20:00:00.000	MEXICO	IRAQ	4	0	Friendlies	mexico
5	2022-11-16 19:30:00.000	MEXICO	SWEDEN	1	2	Friendlies	mexico
6	2022-11-22 16:00:00.000	MEXICO	POLAND	0	0	World Cup	mexico
7	2022-11-26 19:00:00.000	ARGENTINA	MEXICO	2	0	World Cup	mexico
8	2022-11-30 19:00:00.000	SAUDI ARABIA	MEXICO	1	2	World Cup	mexico

3.3. Reportabilidad Histórica

Este sistema permite que el cuerpo técnico de la federación mexicana de fútbol pueda realizar comparativas evaluando los posibles rivales de México, así como la evolución de cada año a partir del 2022 y hasta el año 2026.

Gracias a la acumulación histórica de los datos en la capa final es posible ejecutar consultas utilizando Amazon Athena para extraer métricas estratégicas, como el porcentaje de victoria de los equipos rivales, los goles anotados o recibidos y el desempeño general por el tipo de torneo, con estos datos se puede conocer si un equipo suele ser más ofensivo o defensivo, de forma que se podría planear una alineación adecuada para el partido.




4. Casos de Uso

Caso 1:

El Analista táctico quiere preparar el partido del próximo 11 de junio contra Sudáfrica.
Resultado:

El analista táctico consulta en Amazon Athena el historial de Sudáfrica desde 2022. El sistema devuelve los KPIs disponibles en la Capa Gold: porcentaje de victorias, empates y derrotas, promedio de goles anotados y recibidos por partido, y rendimiento diferenciado por tipo de torneo (amistosos vs. partidos oficiales FIFA). Con base en estas métricas, el cuerpo técnico puede identificar si Sudáfrica tiende a ser un equipo ofensivo o defensivo y planear la alineación más adecuada para el partido.



Caso 2:


Se detecta un error en la fuente original.

Resultado:

El sistema permite realizar un *backfill* o reprocesamiento para corregir los datos históricos de manera íntegra. El Data Engineer corrige los archivos afectados en la Capa Bronze y re-ejecuta el *Glue Job silver1* mediante el comando

aws glue start-job-run --job-name silver1.

El pipeline sobrescribe los archivos Parquet corregidos en la Capa Silver, el Glue Crawler actualiza el catálogo automáticamente y los datos quedan disponibles en Athena sin necesidad de intervención adicional.



```
CloudShell

us-east-1 | +

~ $ aws glue start-job-run --job-name silver1
{
  "JobRunId": "jr_010bb89064f9910f111324a100621e661e914547e2d9ca03444ea538928398be"
}
~ $
```

5. Reglas de Negocio

1. Solo se procesan partidos con valores de goles entre 0 y 20 por equipo. Registros fuera de este rango son descartados automáticamente por el pipeline como datos anómalos.
2. Los nombres de las selecciones (equipo_local y equipo_visitante) deben almacenarse siempre en mayúsculas y sin espacios al inicio o al final para garantizar consistencia en las búsquedas y agrupaciones.
3. El campo fecha debe ser válido y convertible a tipo Timestamp. Los datos se particionan obligatoriamente por selección y por año dentro de S3 para garantizar la eficiencia de las consultas en Amazon Athena.

6. Glosario de Términos para el Usuario

Capa Bronze (Datos Crudos)

Primera capa del Data Lake donde se almacenan los datos tal como llegan de API-Football, en formato CSV, sin ninguna transformación. Es el respaldo puro del histórico.

Capa Silver (Datos Limpios)

Segunda capa donde los datos ya fueron limpiados, tipados y estandarizados por el Glue Job. Se almacenan en formato Parquet, particionados por selección y año. Es la fuente de verdad del sistema.

Capa Gold (KPIs y Métricas)

Capa final de consumo que contiene los indicadores estratégicos agregados (victorias, empates, derrotas, goles y porcentaje de efectividad por selección). Es la que consulta directamente el cuerpo técnico mediante Amazon Athena.

Equipo visitante

Selección que juega fuera de su país o sede durante un partido.

Empate

Resultado de un partido en el que ambos equipos terminan con la misma cantidad de goles.

Fixture

Partido oficial de fútbol entre dos selecciones nacionales.

Goles en contra

Cantidad total de goles recibidos por un equipo.

Goles a favor

Cantidad total de goles anotados por un equipo.

Fase de grupos

Etapla inicial de un torneo donde las selecciones compiten dentro de grupos antes de avanzar a eliminación directa.

Partidos históricos

Encuentros disputados anteriormente y utilizados para análisis estadístico.

Fase eliminatoria

Etapla del torneo donde el equipo que pierde queda eliminado inmediatamente.

Derrotas

Cantidad total de partidos perdidos por un equipo.

Promedio por partido

Valor promedio calculado por encuentro, como goles anotados o recibidos.

Selección nacional

Equipo oficial que representa a un país en competencias internacionales.

Oponente

Equipo rival que enfrenta a otro durante un partido.

Puntos

Sistema de puntuación utilizado en torneos de fútbol:

- Victoria = 3 puntos
- Empate = 1 punto
- Derrota = 0 puntos

Rival

Selección competidora analizada dentro del proyecto.

Marcador

Resultado final de un partido.

Ejemplo: México 2 - 1 Corea del Sur.

Torneo

Competencia oficial de fútbol donde participan selecciones nacionales, como la Copa Mundial o la Copa Oro.

Victorias

Cantidad total de partidos ganados por un equipo.

Porcentaje de victorias

Porcentaje de triunfos respecto al total de partidos disputados.

Ganados

Partidos en los que un equipo anotó más goles que su rival.