

Documentación de Arquitectura de Datos de Fútbol

Implementación de Data Lake House en AWS para Analítica Avanzada

Proyecto desarrollado para
Federación Mexicana de Futbol

Implementado por
Equipo 6 - Ingeniería de Datos, UNAM 2026.

26 de mayo de 2026


1. Resumen Ejecutivo

El objetivo del sistema es realizar la ingesta, limpieza, transformación y análisis de los datos históricos de partidos para las selecciones nacionales rivales, tomando en cuenta la proximidad del mundial de 2026.

La solución implementa una arquitectura Data Lakehouse bajo el patrón Medallion (Bronze, Silver, Gold) utilizando servicios completamente gestionados en la nube de Amazon Web Services (AWS). Permite transformar datos crudos provenientes de fuentes externas en ventajas competitivas y métricas de rendimiento deportivo (KPIs) de alta confiabilidad para la toma de decisiones tácticas.

2. Diagrama de Arquitectura (Conceptual)

La arquitectura sigue un linaje desacoplado donde el almacenamiento y el cómputo se escalan de forma independiente:



3. Stack Tecnológico

Para garantizar la resiliencia, velocidad de procesamiento distribuido y en entorno Serverless que minimice los costos de operación, se utilizaron los siguientes componentes en el ecosistema de AWS:

- **Fuentes de datos:**

API-Football, (proveedor externo de estadísticas históricas de partidos internacionales de fútbol, consumida mediante peticiones HTTP en formato JSON/CSV)

- **Servicio de ingesta, Amazon EC2 (Elastic Compute Cloud):**

Una instancia virtual encargada de ejecutar de forma cronometrada los scripts de extracción en Python para consumir la API externa.

- **Almacenamiento Centralizado (Data Lake):**

Amazon S3 (Simple Storage Service), el núcleo de almacenamiento, segmentado jerárquicamente en los buckets/carpetas de las capas de madurez de datos (Bronze,Silver,Gold)

- **Procesamiento de Big Data (ETL), AWS Glue Jobs:**

Un motor de Spark Serverless optimizado para ejecutar transformaciones distribuidas de PySpark a gran escala sin necesidad de administrar clústeres físicos.

- **Catálogo y Gobernanza, AWS Glue Data Catalog & Crawlers:**

Encargados de inferir de forma automática el esquema de las estructuras optimizadas y exponerlas como tablas lógicas.

- **Capa de Consumo y Analítica, Amazon Athena:**

Un motor de consultas interactivas Serverless que permite ejecutar instrucciones SQL estándar directamente sobre los archivos almacenados en Amazon S3.

4. Descripción de Capas (Medallion Architecture)

Capa	Descripción del Proceso	Tecnología
Bronze (Raw)	Aloja datos en su formato original. No se aplica ninguna transformación, preservando el histórico puro para alguna auditoría o re-procesamientos	Amazon S3 / Archivos en CSV de cada selección
Silver (Trusted)	Contiene los datos limpios y enriquecidos. Se aplican transformaciones de tipo estricto, eliminación de nulos y estandarización de strings de texto. Los datos se convierten a un formato optimizado para analítica.	Amazon S3 / Formato de almacenamiento columnar (Parquet) particionado nativamente por año.
Gold (Refined)	Capa de consumo final. Almacena las vistas agregadas y métricas de negocio deportivo calculadas a partir de la capa silver. Está optimizada para responder preguntas específicas.	Amazon S3 / Consultas estructuradas en tablas mediante Amazon Athena

5. Flujo de Datos (Pipeline)

1. Extracción e ingesta:

Una instancia de Amazon EC2 ejecuta de forma programada scripts en Python que realizan peticiones HTTP al endpoint de API-Football, descargando el histórico de partidos de cada selección nacional en formato CSV/JSON. Los archivos extraídos se depositan directamente en la Capa Bronze del bucket centralizado

s3://unam-2026-ingenieriadatos-equipo6/1bronze/

2. Procesamiento Distribuido (ETL):

Un job de AWS Glue carga los datos crudos en un DataFrame de Spark. El script se ejecuta de forma distribuida las siguientes tareas de calidad de datos:

- Remoción de registros nulos en campos de control críticos
- Estandarización de textos (limpieza de espacios en blanco mediante trim y conversión de mayúsculas con upper)
- Formateo de la columna de tiempo a tipo Timestamp
- Casteo de goles locales y visitantes a tipo Entero (Integer)

3. Optimización y Escritura:

Los datos limpios se exportan a la ruta de la capa Silver utilizando el formato Parquet. Para optimizar búsquedas analíticas y reducir drásticamente los tiempos de escaneo, se aplica un particionamiento físico por año, guardando las estructuras de manera aislada por selección

4. Descubrimiento de metadatos:

Un AWS Glue Crawler analiza periódicamente la capa Silver. Al detectar las nuevas carpetas particionadas, actualiza el AWS Glue Data Catalog, sincronizando las tablas para consulta inmediata.

5. Generación de Insights (Capa Gold):

A través de Amazon Athena, el cliente interesado ejecuta consultas analíticas en lenguaje SQL para calcular métricas avanzadas (porcentaje de victorias, promedio de goles a favor y en contra por partido, rendimiento histórico en contextos específicos), listas para el consumo estratégico.

6. Consideraciones de Seguridad

- **Políticas de Menor Privilegio:**

El acceso a los recursos está restringido mediante roles de AWS IAM (Identity and Access Management), limitando estrictamente los permisos de escritura del Job de Glue únicamente a sus buckets correspondientes

- **Eficiencia en Costos:**

El uso de Parquet y consultas particionadas en Athena asegura que solo se escaneen los bloques de datos requeridos por la consulta activa, reduciendo los costos de computación de AWS en más de 80% en comparación con el escaneo de archivos de texto