

Statement of Work (SOW) - Proyecto de Implementación de Data Lake

Implementación de Data Lake House en AWS para Analítica Avanzada

Proyecto desarrollado para

Caleb S.A. de C.V.

Implementado por

Equipo 6- Ingeniería de Datos, UNAM 2026.

26 de mayo de 2026

1. Contexto del Proyecto

Caleb S.A. de C.V. requiere una solución de ingeniería de datos que permita procesar y analizar el histórico de partidos de la selecciones nacional de fútbol proveniente de la API externa API-Football que vayan a estar directamente asociadas a la selección nacional mexicana de fútbol. La falta de una arquitectura centralizada dificulta la generación de KPIs estadísticos confiables sobre el desempeño de las selecciones a nivel internacional que ayuden a determinar áreas de oportunidad para la selección mexicana.

2. Resumen del Proyecto

El objetivo de este proyecto es diseñar y construir una arquitectura de Data Lake basada en Amazon Web Services AWS que permita el almacenamiento escalable en Amazon S3 bajo una arquitectura de tres capas (Bronze, Silver y Gold), y su procesamiento analítico mediante AWS Glue y Amazon Athena.

La solución consolida los datos en un almacén Formato Parquet, particionado por selección y año, dependiente del catálogo de AWS Glue y consultado mediante SQL estándar a través de Amazon Athena, facilitando la toma de decisiones basada en información precisa sobre el desempeño deportivo de las selecciones analizadas.

3. Alcance del Trabajo (SOW)

El equipo consultor será responsable de las siguientes actividades:

3.1 Ingesta de Datos

Configuración del pipeline de extracción de datos desde la API-Football hacia la zona *Landing* de Amazon S3. Los archivos serán almacenados en formato .csv en la siguiente ruta:

s3://unam-2026-ingenieriadatos-equipo6/1bronze/

3.2 Almacenamiento y Organización

Implementación de una arquitectura de tres capas en el bucket:

unam-2026-ingenieriadatos-equipo6

- Bronze (/1bronze/):
Datos crudos directamente extraídos de la API, sin transformación.
- Silver (/2silver/):
Datos limpios, particionados en formato Parquet. Ruta: /2silver/[seleccion]/year=YYYY/
- Gold (/3gold/):
Vistas agregadas con KPIs de alto valor de negocio listos para consumo analítico.

3.3 Procesamiento ETL/ELT

Desarrollo y ejecución de procesos de transformación de datos para limpieza, normalización y enriquecimiento sobre los datos Bronze.

- **Codificación UTF-8** para prevenir ruptura de caracteres en nombres de selecciones.
- **Limpieza y estandarización** de cadenas con upper() y trim() sobre campos de equipos.
- **Casteo de tipos:** goles_local e goles_visitante a IntegerType(), fecha a TimestampType().
- **Filtrado de calidad:** exclusión de registros con goles fuera del rango válido (0–20).
- **Escritura optimizada en Parquet** con particionamiento por columna year.

3.4 Capa Analítica

Configuración de Glue (crawler-silver-parquet) para mapear de una manera dinámica cada partición en la capa Silver y exponerlas en el Data Catalog. Se ejecutan las queries SQL en Athena con el propósito de generar por selección, los siguientes datos:

1. Total de partidos disputados
2. Victorias, empates y derrotas
3. Porcentaje de efectividad
4. Goles a favor y goles en contra

4. Entregables

Se espera la entrega de los siguientes elementos para la validación por parte de Caleb S.A. de C.V.:

Entregable	Descripción
Documento de Arquitectura	Diagrama detallado de los servicios de AWS y flujo de datos. Documentación técnica completa del pipeline, inventario de servicios AWS (S3, Glue, Athena, etc), flujo de datos entre capas, diccionario de datos de la Capa Gold y guía de ejecución.
Scripts de Infraestructura	Configuración del bucket S3 (unam-2026-ingenieriadatos-equip06), definición del Glue Job silver1, del Crawler crawler-silver-parquet y roles IAM asociados.
Código de Transformación	Scripts silver1.py de Python/PySpark utilizados para los procesos de limpieza (UTF-8, upper, trim), casteo de tipos (Integer, Timestamp) con las rutinas de limpieza, filtrado de calidad (rango 0-20 goles) y escritura Parquet particionada.
Resultados (Capa Gold)	Queries analíticos ejecutados en Athena. Dashboard interactivo para visualización de datos finales

5. Cronograma Estimado

Periodo	Actividades
Semana 1	Levantamiento de requerimientos y diseño de arquitectura.
Semana 2	Desarrollo del pipeline de ingesta desde API-Football hacia la Capa Bronze. Configuración del Glue Job silver1 y desarrollo del script PySpark silver1.py .
Semana 3	Configuración del Glue Crawler (crawler-silver-parquet), integración con el Data Catalog y habilitación de consultas en Athena. Generación de resultados hacia la Capa Gold.
Semana 4	Pruebas de calidad de datos (QA), validación de reglas de negocio (rango de goles, codificación, tipado, etc).Medición de rendimiento del cluster y entrega final de la documentación correspondiente.

6. Criterios de Aceptación

El proyecto se considerará finalizado y aceptado cuando los datos en la capa final coincidan con las reglas y los siguientes criterios de negocio:

1. Los datos en la Capa Gold coinciden con las reglas de negocio definidas en el Diccionario de Datos (tipos correctos, rango de goles 0–20, campos en mayúsculas).
2. El Glue Job *silver1* completa la transformación Bronze a Silver en un tiempo menor a 2 minutos (tiempo de referencia medido: 1 min 54 seg sobre el cluster Serverless).
3. Amazon Athena retorna resultados de los KPIs (victorias, empates, derrotas, efectividad, goles) sin errores de esquema.
4. El Glue Crawler actualiza correctamente las particiones del Data Catalog tras cada ejecución del job.
5. Los archivos Parquet en la Capa Silver están correctamente particionados por selección (/partition_0/) y año (/year=YYYY/)
6. Los resultados Gold se almacenan correctamente en <s3://unam-2026-ingenieriadedatos-equip6/3gold/>.
7. Funcionamiento correcto del dashboard interactivo.

7. Firmas y Aceptación

Cliente	Equipo Consultor
Aceptado por: Caleb S.A. de C.V. Firma: _____ Fecha: _____	Equipo 6 — Ingeniería de Datos UNAM 2026 Fecha: _____